Guia técnico do projeto de projeção eleitoral

Para: Gabriel Campos Moreira Fernandes (105461) | Equipe: Luka Gouvea (96832) e Gabriel Campos Moreira Fernandes (105461)

Objetivo deste guia. Explicar o que construiremos, quais recursos já estão prontos, o funcionamento dos três métodos e como vamos medir a convergência nos segundos turnos presidenciais de 2010, 2014, 2018, 2022 e 2026.

1. O que queremos descobrir?

A apuração não chega em ordem aleatória: cidades e seções podem transmitir resultados em ritmos diferentes. Por isso, a votação nacional parcial pode estar distante do resultado final. Queremos comparar em cinco segundos turnos o percentual de urnas necessário para três métodos atingirem erro pequeno e persistente.

Pergunta: em que percentual de seções apuradas cada método entra e permanece em uma faixa de erro de 1,00, 0,50 ou 0,25 ponto percentual?

2. Visão geral do experimento

1. Histórico anterior a cada eleição + votos finais do respectivo segundo turno + ordem de apuração, quando verificável
2. Reconstruir a apuração de cada segundo turno quando houver registros cronológicos confiáveis
3. Executar três métodos sobre EXATAMENTE as mesmas urnas observadas
4. Comparar previsão com resultado final e medir erro, estabilidade e convergência

3. O que já existe e de onde virá o código?

Fonte	O que fornece	Uso no projeto
João Gallo - GitHub	Python: regressão de swing, hierarquia Ridge e simulador de 2026.	Base para adaptação a outros anos; não é código original de Mahlmeister.
TSE - Dados Abertos	Votação por seção (2006–2026), boletins e documentação.	Fonte primária dos votos, pesos e histórico.
Mattecca / Mahlmeister	Painéis públicos e descrições metodológicas.	Referências conceituais; não assumir acesso ao código completo.
Tiago Dantas - GitHub	Documentação de outro sistema; repositório informa código privado.	Leitura complementar, não código reutilizável.

4. Método 1: pós-estratificação geográfica (baseline)

Ideia: estimar a votação em cada município e combinar municípios conforme o número esperado de votos válidos, em vez de tratar todos os votos recebidos como uma amostra representativa do Brasil.

Exemplo: A representa 20% dos votos e tem 65% para o candidato X; B representa 30% e tem 48%; C representa 50%, ainda não apurado, e recebe estimativa auxiliar de 40%. Projeção = 0,20×65 + 0,30×48 + 0,50×40 = 47,4%. A parcial sem correção pode ser bem diferente.

Implementar: agregação por município, regra explícita para municípios sem urnas (p.ex. média estadual), estimação do número de votos válidos remanescentes e soma ponderada. Risco: primeiras urnas de um município também podem ser enviesadas.

5. Método 2: regressão de swing (mudança eleitoral)

Ideia: comparar o percentual histórico de cada local com seu percentual atual nas urnas já apuradas. Aprender por regressão quais características explicam a mudança e prever o swing dos locais restantes.

Exemplo ilustrativo: local A: 60% na eleição anterior e 65% na atual, swing +5 pontos; B: 45% → 48%, swing +3 pontos. Uma regressão aprende uma função swing = f(voto histórico, porte, ...). Para o local C, com 30% histórico, suponha swing previsto de +2 pontos; logo, projeção 32%.

1. Locais observados: swing = percentual atual - percentual histórico
2. Ajustar regressão ponderada (apenas locais já observados)
3. Locais pendentes: percentual previsto = histórico + swing previsto
4. Estimar votos válidos e somar votos observados + projetados

Implementar/adaptar: matrizes de características, regressão (p.ex. WLS/Ridge), pesos, limite e normalização de proporções, correspondência de locais entre eleições sucessivas e tratamento de comparecimento.

6. Método 3: regressão hierárquica e shrinkage

Ideia: estimar swing em níveis nacional, regional e estadual. Regiões com poucos votos observados são aproximadas da referência superior; conforme chegam votos, sua própria tendência recebe mais peso.

Exemplo: swing nacional +3 pontos, estadual +12 pontos com apenas 5 unidades de informação. Usando peso w = n/(n+100) = 5/105, a estimativa regularizada vira (1−w)×3 + w×12 = +3,43 pontos, não +12. O peso é ilustrativo.

Implementar/adaptar: estender o método 2 com efeitos regionais/estaduais e penalização Ridge, ou regressões de vários níveis com shrinkage. Comparar com a versão sem hierarquia para medir isoladamente o efeito da regularização.

7. Diferenças entre os três métodos

Método	Conhecimento prévio	Dificuldade central
Pós-estratificação	Peso eleitoral por município; estimativa auxiliar para municípios vazios.	Viés dentro de cada município.
Swing	Votação histórica + mudança aprendida das urnas observadas.	Pareamento histórico e extrapolação para locais não vistos.
Hierárquico	Mesmo histórico do swing, mais níveis geográficos.	Calibração da penalização para não regularizar demais.

8. Como reproduziremos a apuração

Recorte: segundo turno presidencial de 2010, 2014, 2018, 2022 e 2026. As bases de resultados finais existem para esses anos, mas a disponibilidade de uma ordem cronológica confiável precisa ser verificada individualmente antes de aplicar a métrica de convergência.

- Baixar resultados por seção dos segundos turnos de 2010, 2014, 2018, 2022 e 2026 e referências históricas anteriores (como 2006), conforme disponibilidade.
- Utilizar os CSVs de ordem dos BUs de 2026 do repositório de João Gallo; buscar séries equivalentes nos anos anteriores e verificar sua cobertura.
- Distinguir recebimento de BU e totalização. Sem registros temporais verificáveis, não afirmar que a sequência histórica real foi reproduzida.
- Nos anos com cronologia disponível, simular 1%, 2%, 5%, 10% e marcos adicionais, sempre ocultando votos ainda não recebidos.
- Usar os mesmos snapshots para os três modelos e registrar a parcial simples do TSE como baseline.

9. Como mediremos convergência

Erro absoluto: |percentual projetado − percentual final|, em pontos percentuais. Como o estudo considera apenas segundos turnos, o erro absoluto de um candidato é igual ao do outro, pois seus percentuais válidos são complementares.

Convergência sustentada: primeiro percentual de apuração em que o erro fica ≤ ε e não volta a ultrapassar ε até o fim, com ε = 1,00; 0,50; 0,25 p.p. Comparar também a curva de erro e a estabilidade da projeção.

Atenção: esse ponto é calculado *depois* da eleição, pois depende do resultado final. Comparar cinco eleições amplia a evidência, mas não prova confiabilidade universal; a ordem de apuração e a cobertura dos dados precisam ser documentadas por ano.

10. Fontes, repositórios e leitura inicial

Código executável (João Gallo): https://github.com/joaogallo/projecao-apuracao-eleicoes
Portal de Dados Abertos TSE: https://dadosabertos.tse.jus.br/
Documentação Mahlmeister: https://github.com/rodrigomahlmeister/projecao-2026-metodo
Painel Mattecca: https://apuracao.mattecca.com.br/
Documentação Tiago Dantas (código privado): https://github.com/tiagomendesdantas/election-outlook-br
Pavía-Miralles (2005), JASA: https://doi.org/10.1198/016214504000001835
Bernardo e Girón (1992), Bayesian Statistics 4: https://doi.org/10.1093/oso/9780198522669.003.0004
Pavía, Larraz e Montero (2008), JASA: https://doi.org/10.1198/016214507000001427
Critério de sucesso inicial: validar a reconstrução temporal de 2026, adaptar os estimadores aos demais pleitos e apresentar curvas comparáveis nos anos com registros suficientes. Se a cronologia de um ano não estiver disponível, registrar explicitamente a limitação.